

Selección de modelos gráficos no-dirigidos en el contexto de alta dimensión

Violeta Roizman

Directora: Dra. Florencia Leonardi

Codirectora: Dra. Mariela Sued


2017-05-28

Selección de **modelos gráficos** **no-dirigidos en el contexto de alta** **dimensión**

- › **modelos gráficos (?)**
- › **no-dirigidos (?)**
- › **contexto de alta dimensión (?)**

Modelos gráficos

Grafo $\mathcal{G} = (V, E)$



\mathcal{G} representa $\vec{X} = (X_1, \dots, X_p)$ con $|V| = p$

Las aristas codifican dependencias condicionales entre variables

Modelos gráficos no-dirigidos

También llamados campos aleatorios de Markov

Propiedades:

- ▶ aristas sin orientación
- ▶ relaciones simétricas
- ▶ cada vértice es una variable
- ▶ **Un grafo \mathcal{G} representa a un vector $\vec{X} \sim D$ si:**


$$(i,j) \notin E \implies X_i \perp X_j | X_{V \setminus \{i,j\}}$$

Independencia condicional

Definición

X, Y, Z variables aleatorias

$$X \perp Y | Z \iff p(x, y | z) = p(x | z)p(y | z)$$



Intuitivamente

Suponiendo que dado el valor de Z queremos adivinar el valor de X , ¿nos ayudaría conocer el valor de Y ? En caso negativo tendremos que $X \perp Y | Z$.

Propiedades de Markov


Dado un modelo gráfico decimos que se cumple:

- (P) Propiedad de Markov de a pares si $\forall (i,j) \notin E: X_i \perp X_j | X_{V \setminus \{i,j\}}$.

$$X_i \perp X_j | X_{V \setminus \{i,j\}}.$$

- (G) Propiedad de Markov global si para $A, B, C \subset V$ disjuntos tales que C separa a A de B en G entonces

$$X_A \perp X_B | X_C.$$



Objetivo

Dada una muestra finita $\{\mathbf{x}^{(i)}\}_{i=1}^n$ de $\vec{X} \sim D$

$$\mathbf{X} = \begin{bmatrix} \quad & \mathbf{x}^{(1)} & \quad \\ \quad & \mathbf{x}^{(2)} & \quad \\ & \vdots & \\ & \vdots & \\ \quad & \mathbf{x}^{(n)} & \quad \end{bmatrix}$$

Objetivo: estimar \mathcal{G} que represente a \vec{X} a partir de \mathbf{X}

Teorema Hammersley-Clifford

Si D es estrictamente positiva entonces **(G)** \iff **(P)**

Nos permite estimar el grafo con la propiedad **(P)** y deducir con **(G)**

Cuando ya estimamos el grafo


¿Para qué me sirve?

- **Análisis cualitativo:**

Leer independencias condicionales

¿Las variables están agrupadas?

¿Existen variables importantes?



- **Inferencia:** a partir de el valor de algunas de las variables del grafo predecir el valor de otras

Alta dimensión

Base de datos:

- n = número de observaciones
- p = número de variables

Contexto de alta dimensión:


$$n < p$$

Algunas disciplinas:


genética



neurociencia



Ejemplo: problema de regresión



Cuadrados mínimos:

$$\underset{\beta}{\text{minimizar}} \frac{1}{2n} \sum_{i=1}^n ||\mathbf{y} - \beta \mathbf{x}||_2^2$$

Si $p > n$:


- ▶ No puede resolverse con las ecuaciones normales
- ▶ No tiene un único mínimo

Contexto de alta dimensión en modelos gráficos

muchas variables = muchos vértices

$$\# \text{ de parámetros a estimar} = \frac{p(p-1)}{2}$$


esperamos: pocas aristas





Contenido

- ▶ **Dos ejemplos**
- ▶ **(Regresión lineal en alta dimensión)**
- ▶ **Modelo gaussiano**
- ▶ **(Regresión logística en alta dimensión)**
- ▶ **Modelos discretos**
- ▶ **Conclusiones y trabajo a futuro**

Ejemplo 1: red de genes



b




Ejemplo 2: diputados

Quiero saber como se relacionan los diputados al votar



Ley	del Sel	Conti	Heller	Cobos	Sturtzenegger	.
1	0	1	1	0	0	.
2	0	1	0	0	0	.
3	1	1	1	1	0	.
4	1	1	1	1	1	.
5	1	1	1	1	1	.
6	0	0	0	1	0	.
.

Buscamos algo así



(Regresión lineal en alta dimensión)

Penalización norma l_1 : método *lasso*

Volvemos al problema de regresión:

$$\underset{\beta_0, \beta}{\text{minimizar}} \frac{1}{2n} \sum_{i=1}^n \|\mathbf{y} - \beta_0 - \mathbf{x}\beta\|_2^2 + \lambda \|\beta\|_1$$

Propiedades:

- ▶ convexo (único mínimo, fácil de optimizar)
- ▶ $\lambda \rightarrow 0$ **CUADRADOS MÍNIMOS** y $\lambda \rightarrow \infty \hat{\beta} = \mathbf{0}$
- ▶ introduce sesgo - menos varianza
- ▶ tiende a anular coeficientes (carácter selector)
- ▶ selecciona como mucho n variables

¿Por qué norma 1?: *ridge* usa $\|\beta\|_2$
estima a todos los coeficientes distintos $\neq 0$

Modelo Gaussiano


Normal multivariada

Si $\vec{X} \sim N(\mu, \Sigma)$:

$$f(\mathbf{x}; \mu, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)\right)$$

Nos basamos en esta propiedad:

$$\Theta_{ij} := \Sigma_{ij}^{-1} = 0 \iff X_i \perp X_j | X_{V \setminus \{i,j\}} \iff (i,j) \notin E$$



$$\boldsymbol{\Theta} = \begin{pmatrix} 1 & 0.5 & \textcolor{red}{0} & \textcolor{red}{0} & 0.5 \\ 0.5 & 1 & 0.5 & 0.3 & \textcolor{red}{0} \\ \textcolor{red}{0} & 0.5 & 1 & 0.5 & \textcolor{red}{0} \\ \textcolor{red}{0} & 0.3 & 0.5 & 1 & 0.6 \\ 0.5 & \textcolor{red}{0} & \textcolor{red}{0} & 0.6 & 1 \end{pmatrix}$$

Graphical Lasso

Consiste en maximizar la función de verosimilitud penalizada:

$$l_\lambda(\Theta; \mathbf{x}^{(1)}, \dots, \mathbf{x}^{(n)}) = \log(\det(\Theta)) - \text{tr}(\mathbf{S}\Theta) - \lambda\|\Theta\|_1$$

con

$$\mathbf{S} = n^{-1} \sum_{i=1}^n (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}_{MV})(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}_{MV})^T$$

y

$$\|\Theta\|_1 = \sum_{j \neq k} |\Theta_{jk}|$$

Una opción: Elección de λ con validación cruzada con verosimilitud gaussiana negativa como función de pérdida

Graphical Lasso

Ya estimada Σ^{-1} , estimamos E_* :

$$\widehat{E} = \{(j, k) \in V \times V; \widehat{\Sigma}_{jk}^{-1} \neq 0\}.$$

Bajo ciertas condiciones de regularidad con alta probabilidad:

$$E_* \subseteq \widehat{E}$$

Las condiciones para la consistencia son bastante restrictivas

Surgen variaciones de este método (*Adaptive GLasso*)

Nodewise regression

Basándonos en esto:

$$X_j = - \sum_{k \in V \setminus \{j\}} \frac{\Theta_{jk}}{\Theta_{jj}} X_k + \varepsilon_j$$

Para cada $j \in V$ estimo $\widehat{\beta}_k^{(j)}$ haciendo la regresión lineal de X_j vs $X_{V \setminus j}$

$$\widehat{\beta}_k^{(j)} \neq 0 \iff \Theta_{jk} \neq 0$$

Necesito que Θ sea simétrica \implies Regla **OR** o **AND**

Stability Selection

Método basado en re-muestreo combinado con *GLasso*

Consiste en:

1. Elegir Λ una secuencia de posibles valores λ
2. Elegir un valor $50 < \pi < 100$ de corte
3. Estimar la estructura del grafo n_{rep} veces para cada λ
4. Poner cada arista en el grafo final si para alguno de los $\lambda \in \Lambda$ aparece en más del $\pi\%$ de los grafos estimados

La estimación del grafo no depende fuertemente de la elección de Λ ni de la elección π

Estimando el grafo de genes ($p = 160, n = 115$)

Stability Selection Graphical Lasso




Figura: Comparación de la estimación del grafo para el conjunto de datos riboflavin **GLasso** vs. **Stability Selection** con distintos valores del parámetro λ

Estimando el grafo vacío

Stability Selection Graphical Lasso




Figura: Comparación de la estimación del grafo vacío con **Glasso** vs. **Stability Selection** con distintos valores del parámetro λ

(Regresión logística en alta dimensión)

Regresión logística

Clásico método de **clasificación**

- $Y = 0$ o 1 es la variable respuesta
- \vec{X} variables explicativas

Modelo la probabilidad $p(\vec{X})$ de que la variable respuesta valga uno:

$$\text{logit}(p(\vec{X})) := \log\left(\frac{p(\vec{X})}{1 - p(\vec{X})}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p, \quad (*)$$

Función de verosimilitud:

$$l(\beta) = \sum_{i=1}^n y^{(i)} \log(p(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - p(\mathbf{x}^{(i)})).$$

Agrego un término de penalización de la norma de coeficientes β

Regresión logística penalizada

Analizamos los datos prostate: expresión de 6033 genes obtenidas de 102 muestras de pacientes operados

Clasificar a estas muestras como tumores malignos o benignos

Los datos fueron divididos al azar en:
entrenamiento (75 %) y validación (25 %).


	Porcentaje de acierto	Variables seleccionadas
penalización l_1	84 %	23
penalización l_2	92 %	todas

Modelos discretos

Modelo Ising

Probabilidad puntual conjunta para $\mathbf{x} \in \{0, 1\}^p$:

$$p(\mathbf{x}, \Theta, \alpha) = \exp \left[\sum_{j \in V} \alpha_j \mathbf{x}_j + \sum_{(j,k) \in E} \Theta_{jk} \mathbf{x}_j \mathbf{x}_k - \Phi(\Theta, \alpha) \right]$$



De acá se deduce:

$$X_j \perp X_k | X_{V \setminus \{j,k\}} \iff \Theta_{jk} = 0.$$

Nodewise logistic regression

Se basa en:

$$\text{logit}(P[X_j = 1 | X_{V \setminus j}]) = \alpha_j + \sum_{k \neq j} \Theta_{jk} X_k.$$


Para cada $j \in V$:

Hacemos una regresión logística de la variable X_j en función de $X_{V \setminus j}$


$$\beta_j^{(k)} = \Theta_{kj} \text{ y entonces } \beta_j^{(k)} \neq 0 \iff \Theta_{kj} \neq 0.$$

Por cada parámetro 2 estimaciones \implies usamos reglas **AND** u **OR**

Estimando el grafo para palabras ($n = 1000, p = 100$)



Estimando el grafo para diputados ($n = 183, p = 133$)



Estimando el grafo para diputados

Telegram Web | Recibidos (2.15) | banerjee084.pdf | Rector.pdf | El diputado rad... | Nueva pestaña | Un diputado te... | Obras del alcalde | Buscar | 

www.telam.com.ar/notas/201309/34064-el-diputado-radical-por-corrientes-rodolfo-fernandez-dio-quorum-al-oficina

télam | Política | Economía | Sociedad | Provincias | Deportes | Internacional | Espectáculos | Cultura | Turismo | Tecnología | Buscar | Configuración

El diputado radical por Corrientes Rodolfo Fernández dio quórum al oficialismo y renunció a su bloque

El diputado nacional Rodolfo Fernández (UCR-Corrientes) desató la polémica en el radicalismo de la Cámara baja al prestar quórum al oficialismo en el debate por las leyes económicas y difundir luego su renuncia al bloque radical.



UBICACIÓN

Congreso de la Nación Argentina

Datos de mapas ©2017 Google

ÚLTIMOS VIDEOS

La Policía británica ide...

Foto Fernando Statta / Telam

17:10 23/5/2017

Conclusiones y trabajo a futuro


Conclusiones:

- ▶ Efecto selector de la penalización con norma 1
- ▶ *Stability Selection* como una forma simple de reducir la dependencia de λ
- ▶ Marcada separación en grupos de variables

Trabajo a futuro:

Estudiar algunas variantes de estos modelos

- ▶ continuos no normales
- ▶ modelos mixtos
- ▶ con datos faltantes
- ▶ con variables ocultas



¡Gracias!
